



Universidad Veracruzana

Facultad de Estadística e Informática

Región: Xalapa

Licenciatura en Ingeniería en Ciberseguridad e Infraestructura de Computo

Estado del arte de las medidas de seguridad a nivel de aplicación en el contexto de ataques de inyección de *prompt* dirigidos a sistemas basados en LLM

Presentación de avances para la EE Proyecto Guiado

Presenta:

Abraham Núñez Sánchez

Director:


Héctor Xavier Limón Riaño

Septiembre 2026

“Lis de Veracruz: Arte, Ciencia, Luz”

Antecedentes (1/3) - Contexto

- De acuerdo con Fortinet (2026), la ciberseguridad ya no es solo una función de TI, sino una prioridad principal del negocio.
- En los últimos años, una de las tendencias en el área de la tecnología es la inteligencia artificial generativa en aplicaciones de uso cotidiano y profesional.
- Los modelos de lenguaje grandes (LLM) son modelos de aprendizaje entrenados con grandes cantidades de datos, lo que les permite comprender y generar lenguaje natural para realizar diversas tareas, según IBM.



Antecedentes (2/3) – Sistemas basados en LLM y la inyección de *prompt*

- Vassilev et al. (2025) en el documento “*Adversarial Machine Learning*” señala que los LLM pueden integrarse en aplicaciones de software y combinarse con bases de datos, documentos y herramientas externas.



- La inyección de *prompt* son aquellos ataques donde el usuario proporciona instrucciones dentro del contexto que son incorporadas junto con instrucciones de mayor nivel de confianza (Vassilev et al., 2025).

Antecedentes (3/3) – Trabajos previos

Titulo	Descripción	Aporte
<i>A Systematic Review of Prompt Injection Attacks on Large Language Models: Trends, Taxonomy, Evaluation, Defenses, and Opportunities.</i>	Duarte et al. (2026) Realizan una revisión sistemática sobre ataques de inyección de <i>prompt</i> , abordando su evolución, taxonomías, métodos de evaluación y estrategias de defensa.	Proporcionar una visión estructurada del estado del campo e identificar oportunidades de investigación.
<i>Prompt Injection Attacks on Large Language Models: A Survey of Attack Methods, Root Causes, and Defense Strategies.</i>	Geng et al. (2026) Analizan 128 estudios sobre métodos de ataque, causas de vulnerabilidad, defensas y evaluación.	Clasifican las defensas en procesamiento de entradas, arquitectura del sistema y nivel del modelo, además de identificar limitaciones en los métodos de evaluación.
<i>The Landscape of Prompt Injection Threats in LLM Agents: From Taxonomy to Analysis.</i>	Wang et al. (2026) Estudian las amenazas de inyección de <i>prompt</i> en agentes basados en LLM.	Clasifican las defensas según su intervención en los niveles de texto, modelo y ejecución, y proponen <i>AgentPI</i> para evaluar defensas en escenarios dependientes del contexto.

Problemática



- La literatura incluye diversidad de propuestas, pero estas aparecen en estudios con diferentes objetivos, escenarios y métodos de evaluación.
- Una medida que presenta buenos resultados en un escenario determinado no necesariamente ofrece el mismo nivel de protección cuando se utiliza en otro contexto o ante otro tipo de inyección.
- **El conocimiento sobre las medidas de seguridad frente a los ataques de inyección de *prompt* se encuentra disperso, particularmente en aquellas que pueden implementarse a nivel de aplicación.**

Preguntas de investigación (I/2) – Pregunta principal

- ¿Qué medidas de seguridad a nivel de aplicación han sido propuestas y evaluadas frente a los ataques de inyección de *prompt* en sistemas basados en LLM, y cuáles son sus principales características, alcances, limitaciones y criterios de evaluación?

Preguntas de investigación (2/3) – Preguntas complementarias

- ¿Qué es un ataque de inyección de *prompt* y cuáles son las categorías que presenta?
- ¿Qué medidas de seguridad a nivel de aplicación han sido propuestas en la literatura reciente para reducir los ataques de inyección de *prompt* en sistemas basados en LLM?
- ¿Cómo pueden clasificarse las medidas de seguridad identificadas de acuerdo con el punto de intervención dentro del sistema basado en LLM?

Preguntas de investigación (3/3) – Preguntas complementarias

- ¿En qué contextos y escenarios han sido evaluadas las medidas identificadas, qué tipos de ataques abordan y qué criterios se utilizan para determinar su efectividad?
- ¿Qué limitaciones y compromisos entre seguridad, utilidad, rendimiento, costo o complejidad de implementación han sido reportados para las medidas analizadas?
- ¿Qué cosas permanecen abiertas o insuficientemente en la literatura sobre medidas de seguridad a nivel de aplicación frente a ataques de inyección de *prompt*?

Objetivos (1/2) - Objetivo general

- Analizar las medidas de seguridad a nivel de aplicación frente a ataques de inyección de *prompt* en sistemas basados en LLM, mediante la revisión, clasificación, comparación y síntesis de literatura científica reciente, con el propósito de identificar sus características, contextos de aplicación, alcances, limitaciones y criterios de evaluación.

Objetivos (2/3) - Objetivos específicos

- OE-01: Identificar los ataques de inyección de *prompt* que pueden ser mitigados desde el lado de la aplicación.
- OE-02: Analizar las medidas de seguridad a nivel de aplicación propuestas en la literatura reciente para mitigar los ataques de inyección de *prompt* en sistemas basados en LLM.
- OE-03: Clasificar las medidas de seguridad identificadas de acuerdo con el punto de intervención dentro del sistema.

Objetivos (3/3) - Objetivos específicos

- OE-04: Identificar las taxonomías existentes para clasificar las mitigaciones de ataques de inyección de *prompt* a nivel de aplicación.
- OE-05: Analizar las formas en las que se evalúan las medidas de seguridad reportadas en la literatura considerando los tipos de ataques abordados, contextos de aplicación, criterios de evaluación, efectividad, impacto sobre la utilidad y limitaciones.
- OE-06: Discutir los alcances y limitaciones que permanezcan abiertos para futuras investigaciones.

Justificación

- Autores como Kumar et al. (2024) que presentan un marco que clasifica diversos ataques de inyección de *prompt* en base a diversas características como el *prompt* utilizado, el tipo de confianza que violaron y el nivel de experiencia requerido reafirma que estos ataques pueden presentarse en diferentes escenarios.
- Existe una diversidad de medidas de seguridad propuestas que presentan diferentes alcances, limitaciones y criterios de evaluación.
- **Las revisiones existentes abordan el fenómeno de manera amplia o desde distintos niveles de intervención. Este trabajo se delimita a medidas de seguridad a nivel de aplicación, con énfasis en sus características, contexto de aplicación, evaluación y limitaciones.**


Delimitación del trabajo

Alcances

- Alcance de tipo descriptivo.
- Literatura científica no mayor a cinco años en ingles.
- Literatura que sea accesible mediante motores de búsqueda con acceso institucional como ACM, *Springer*, *ScienceDirect* e IEEE.
- Centrada en el área de ciberseguridad analizando los ataques y mitigaciones.
- Medidas de seguridad que pueden implementarse a nivel de aplicación.

Limitaciones

- Artículos o revisiones que no puedan ser accedidos por medios institucionales.
- Artículos o revisiones que no hayan sido publicados o revisados oficialmente.
- Medidas de seguridad que modifiquen el LLM.




Método de investigación - Kitchenham

- Es un marco para realizar revisiones sistemáticas de literatura especializado en la ingeniería de software
- Busca minimizar el sesgo mediante protocolo definidos, estrategias de búsqueda auditables y criterios estrictos de inclusión de estudios.
- Kitchenham define la revisión sistemática de literatura como una forma de identificar, evaluar e interpretar la mayor cantidad de información disponible y relevante sobre un tema.
- Una revisión sistemática es un estudio secundario mientras que los estudios individuales que contribuyen a la revisión son estudios primarios.

Método de investigación – Etapas del método Kitchenham

Fases del metodo de Kitchenham



Estructura del trabajo recepcional

- 1. Introducción
 - 1.1. Antecedentes
 - 1.2. Definición del problema
 - 1.3. Objetivos
 - 1.3.1. Objetivo general
 - 1.3.2. Objetivos específicos
 - 1.4. Justificación
 - 1.5. Delimitación del proyecto
 - 1.5.1. Alcance
 - 1.5.2. Limitación
 - 2. Marco teórico
 - 2.1. Ciberseguridad
 - 2.1.1. Ciberataque
 - 2.1.1.1. Vector de ataque
 - 2.1.1.2. Vulnerabilidad
 - 2.1.1.3. Amenaza
 - 2.1.1.4. Mitigación
 - 2.2. LLM
 - 2.2.1. Sistema basado en LLM
 - 2.2.1.1. Aplicación basada en LLM's
 - 2.2.1.2. *Prompt*
 - 2.2.2. Entrenamiento de LLM
3. Método de investigación
4. Resultados
 - 4.1. Cuantitativos
 - 4.2. Cualitativos
5. Discusión
6. Amenazas a la validez
7. Conclusiones y trabajo futuro

Cronograma

Actividades	Meses																
	2026					2027											
	Agosto	Septiembre	Octubre	Noviembre	Diciembre	Enero	Febrero	Marzo	Abril	Mayo	Junio	Julio	Agosto	Septiembre	Octubre	Noviembre	Diciembre
Protocolo de investigación																	
Protocolo de la revisión																	
Selección de cadena de búsqueda																	
Selección de estudios primarios																	
Extracción de datos																	
Síntesis narrativa																	
Reporte de la revisión																	
Concentrarse en una o dos fuentes de información																	
Explorar más fuentes y snowballing																	
Ampliar selección de estudios																	
Realizar extracción de nuevos estudios																	
Realizar síntesis sistematica																	
Escribir un borrador de artículo																	
Desarrollo de marco teórico																	
Definición de la discusión																	
Definición de la conclusión																	
Trabajo futuro																	

Referencias

- ¿Qué es la ciberseguridad? Tipos, amenazas y mejores prácticas | Fortinet. (n.d.). Fortinet.
<https://www.fortinet.com/lat/resources/cyberglossary/what-is-cybersecurity>
- ¿Qué son los LLM? | IBM. (2026, August 16). <https://www.ibm.com/mx-es/think/topics/large-language-models>
- Vassilev, A. (2025). Adversarial Machine Learning: <https://doi.org/10.6028/NIST.AI.100-2e2025>
- What is a prompt injection attack? [Examples & Prevention]. (n.d.). Palo Alto Networks.
<https://www.paloaltonetworks.com/cyberpedia/what-is-a-prompt-injection-attack>
- Damacena Duarte, J., Cândido, G. D., de Britto Filho, J. R. A., Souza Neto, J., da Costa, E. J., da Costa, J. P. J., & Peotta De Melo, L. (2026). A Systematic Review of Prompt Injection Attacks on Large Language Models: Trends, Taxonomy, Evaluation, Defenses, and Opportunities. In IEEE Access (Vol. 14, pp. 12875–12899). Institute of Electrical and Electronics Engineers Inc. <https://doi.org/10.1109/ACCESS.2026.3656849>
- Geng, T., Xu, Z., Qu, Y., & Wong, W. E. (2026). Prompt Injection Attacks on Large Language Models: A Survey of Attack Methods, Root Causes, and Defense Strategies. In Computers, Materials and Continua (Vol. 87, Issue 1). Tech Science Press.
<https://doi.org/10.32604/cmc.2025.074081>
- Wang, P., Li, X., Xiang, C., Zhang, J., Li, Y., Zhang, L., Wang, X., & Tian, Y. (2026). The Landscape of Prompt Injection Threats in LLM Agents: From Taxonomy to Analysis. <http://arxiv.org/abs/2602.10453>
- Kumar, S. S., Cummings, M. L., & Stimpson, A. (2024). Strengthening LLM Trust Boundaries: A Survey of Prompt Injection Attacks Suresh Kumar Dr. M.L. Cummings Dr. Alexander Stimpson. 2024 IEEE 4th International Conference on Human-Machine Systems, ICHMS 2024. <https://doi.org/10.1109/ICHMS59971.2024.10555871>
- Kitchenham, B. (2007). Guidelines for performing Systematic Literature Reviews in Software Engineering.
<https://www.researchgate.net/publication/302924724>