Universidad Veracruzana
Facultad de Estadística e Informática
Región Xalapa

Licenciatura en Ingeniería de Ciberseguridad e Infraestructura de Cómputo

Medidas de seguridad a nivel de aplicación en el contexto de ataques de inyección de prompt dirigidos a sistemas basados en LLM: Una revisión de literatura

Protocolo de Revisión Sistemática para acreditar la EE Proyecto Guiado

Presenta:
Abraham Núñez Sánchez

Director:
Héctor Xavier Limón Riaño

Octubre de 2026

"Lis de Veracruz: Arte, Ciencia, Luz"



Universidad Veracruzana

Facultad de Estadística e Informática
Región Xalapa

Licenciatura en Ingeniería de Ciberseguridad e Infraestructura de Cómputo

Medidas de seguridad a nivel de aplicación en el contexto de ataques de inyección de *prompt* dirigidos a sistemas basados en LLM: Una revisión de literatura

Protocolo de Revisión Sistemática para acreditar la EE Proyecto Guiado

Presenta:
Abraham Núñez Sánchez

Director:
Héctor Xavier Limón Riaño

Índice

1. Introducción 3
2. Preguntas de investigación 5
3. Estrategia de búsqueda 7
    3.1. Identificar fuentes 8
    3.2. Búsqueda manual 8
    3.3. Conceptos y términos 14
    3.4. Creación de cadenas y validación de cadenas 17
        3.4.1. Cadenas finales 22
4. Selección de estudios primarios 23
    4.1. Criterios de inclusión 23
    4.2. Criterios de exclusión 23
    4.3. Procedimiento de selección de estudios primarios 24
5. Extracción de datos 25
6. Estrategia para la síntesis de datos 26
    6.1. Desarrollo de una teoría 27
    6.2. Desarrollo de una síntesis preliminar 27
    6.3. Exploración de las relaciones dentro y entre estudios 28
    6.4. Evaluación de la robustez del producto de la síntesis 28
7. Limitaciones 29
8. Informe 30
9. Gestión de la revisión 32
Referencias 33

1. Introducción

Los sistemas basados en modelos grandes de lenguaje (LLM) se han incorporado de forma creciente en aplicaciones de uso cotidiano y profesional, permitiendo tareas como generación de texto, análisis de información, consulta de documentos e interacción con herramientas externas (IBM, 2026). Esta integración, sin embargo, introduce un riesgo de seguridad: los ataques de inyección de prompt, en los que instrucciones maliciosas son incorporadas directamente por un usuario o indirectamente a través de fuentes externas procesadas por el sistema (Vassilev et al., 2025).

Greshake et al. (2023) muestran que esta vulnerabilidad surge de la dificultad de los sistemas basados en LLM para separar datos de instrucciones dentro de un mismo contexto de procesamiento, lo que permite que contenido manipulado por un atacante altere el comportamiento esperado del sistema. Frente a esta amenaza, la literatura ha propuesto una variedad de medidas de mitigación que intervienen en distintos componentes y niveles del sistema desde el ajuste o reentrenamiento del propio modelo, hasta controles implementados externamente a nivel de aplicación, sin modificar su arquitectura interna.

Esta revisión se enfoca específicamente en ese segundo nivel: las medidas de seguridad que pueden implementarse a nivel de aplicación, es decir, sobre los componentes que integran y rodean al LLM, considerando mecanismos como el procesamiento de entradas, la construcción de prompts, la detección de contenido malicioso, la validación de salidas, el control de herramientas y el monitoreo de actividad.

La importancia de esta revisión responde directamente al problema de investigación identificado: Existe una dispersión del conocimiento existente sobre las medidas de seguridad a nivel de aplicación. Estas propuestas aparecen en estudios con diferentes objetivos, escenarios de aplicación y criterios de evaluación, lo que puede dificultar obtener una visión organizada de qué medidas existen, cómo funcionan y bajo qué condiciones son efectivas.

Esta dispersión tiene consecuencias prácticas concretas. Geng et al. (2026), por ejemplo, reportan que los ataques pueden superar el 90% de éxito en sistemas sin protección, mientras que las medidas de preprocesamiento de entradas alcanzan tasas de detección de entre 60% y 80%, y algunas defensas arquitectónicas llegan hasta 95% de protección frente a patrones conocidos pero advierten limitaciones significativas frente a ataques novedosos. De forma similar, Wang et al. (2026) documentan que las medidas de seguridad pueden presentar compromisos entre confiabilidad, utilidad y latencia, especialmente en tareas dependientes del contexto.

La identificación de brechas de investigación actuales, particularmente en lo relativo a marcos de evaluación estandarizados y a la generalización de las defensas frente a ataques novedosos. Un marco o contexto organizado que permita posicionar y comparar las propuestas existentes según su punto de intervención dentro del sistema, los tipos de ataque que abordan y los criterios usados para evaluarlas.

Esta síntesis beneficiará tanto a interesados en seguridad de sistemas basados en LLM como a perfiles de administración de ciberseguridad y de desarrollo de software, quienes podrán usar esta evidencia como referencia al evaluar riesgos y alternativas de protección aplicables a sus propios sistemas.

Ya existen revisiones sistemáticas sobre inyección de prompt que preceden a este trabajo, cada una con un enfoque distinto:

- Duarte et al. (2026) realizan una revisión centrada en la evolución, taxonomías, técnicas de ataque, métodos de evaluación y estrategias de defensa de la inyección de prompt de forma amplia, sin diferenciar sistemáticamente el nivel de intervención de cada medida.
- Wang et al. (2026) sistematizan 78 trabajos sobre ataques y defensas en agentes basados en LLM, clasificando las defensas según su etapa de intervención como texto, modelo y ejecución, además de evaluar compromisos entre efectividad, utilidad del agente y costo computacional.

- Matthew E.S. (2025) explora métodos de inyección orientados a inducir respuestas dañinas y propone un marco de clasificación de ataques y defensas, también sin enfocarse en el punto de intervención del sistema.

Estas revisiones permiten observar un panorama amplio de ataques y medidas de mitigación, pero ninguna delimita su análisis exclusivamente a las medidas implementables a nivel de aplicación, es decir, aquellas que no requieren modificar el entrenamiento ni la arquitectura interna del LLM. Esta es precisamente la brecha que está revisión busca cubrir: organizar y sintetizar la evidencia disponible sobre ese nivel específico de intervención, identificando sus características, contextos de aplicación, criterios de evaluación, y los compromisos entre seguridad, utilidad, rendimiento y complejidad de implementación reportados en la literatura.

2. Preguntas de investigación

Las preguntas de investigación (RQ, por sus siglas en inglés) son el elemento central de una Revisión Sistemática de Literatura. Kitchenham et al. (2016) las consideran una parte crítica de la planificación, porque guían todo el proceso de revisión y no solo su inicio. Los autores señalan que las preguntas determinan, como mínimo, tres decisiones:

- Qué estudios primarios se incluyen. Las preguntas orientan los criterios de inclusión y exclusión, por tanto, también orientan la estrategia de búsqueda. Las cadenas de búsqueda se derivan de los conceptos y términos que aparecen en ellas.
- Qué datos se extraen. Solo se recolecta la información necesaria para responder cada pregunta, lo que evita extraer datos irrelevantes.
- Cómo se sintetizan o agregan los resultados. El método de síntesis debe permitir responder las preguntas planteadas.

Tabla 1.

Preguntas de investigación para la revisión sistemática de literatura.

Identificador	Pregunta de investigación	Motivación
P1	¿Cuáles son los tipos de inyección de prompt a nivel de aplicación en los sistemas basados en LLM?	Esta identificación permitirá delimitar los ataques abordados en la literatura y comprender cuáles pueden ser atendidos mediante medidas de seguridad implementadas a nivel de aplicación.
P2	¿Qué medidas de seguridad a nivel de aplicación han sido propuestas en la literatura reciente para reducir los ataques de inyección de prompt en sistemas basados en LLM?	Esta pregunta permite generar una visión general de las soluciones existentes sin asumir que todas ofrecen el mismo nivel de protección o que son aplicables a cualquier sistema basado en LLM.
P3	¿Qué tipo de categorías existen para las medidas de seguridad identificadas de acuerdo con el punto de intervención dentro del sistema basado en LLM?	Clasificarlas según su punto de intervención permitirá organizar las propuestas identificadas, reconocer sus similitudes y diferencias, y facilitar la comparación entre medidas que actúan sobre componentes o procesos equivalentes.
P4	¿En qué escenarios han sido implementadas las medidas de seguridad identificadas en la literatura?	Permitirá comprender en qué tipos de sistemas se han aplicado las medidas, qué modalidades de ataque se han considerado y hasta qué punto los resultados reportados pueden ser pertinentes para otros contextos.
P5	¿Cómo se evalúan las medidas de seguridad para determinar su efectividad contra los ataques de inyección?	Analizar estos elementos permitirá comparar los resultados con mayor rigor e identificar las diferencias que deben considerarse al interpretar la efectividad reportada por cada estudio.
P6	¿Qué limitaciones y retos han sido reportadas para las medidas de seguridad analizadas contra ataques de inyección de prompt?	Identificar estos problemas permitirá establecer los alcances reales de las propuestas analizadas y comprender los compromisos que pueden existir entre seguridad, utilidad, rendimiento y complejidad de implementación.
P7	¿Qué líneas de trabajo futuro permanecen abiertas en la literatura sobre medidas de seguridad a nivel de aplicación frente a ataques de inyección de prompt?	Esta identificación contribuirá a resaltar las principales necesidades de investigación en el área y a señalar oportunidades para futuros estudios.

3. Estrategia de búsqueda

Para esta investigación se adoptó la Revisión Sistemática de Literatura (RSL) como método de estudio secundario. Una RSL busca identificar de forma objetiva, analítica y repetible la evidencia relevante sobre un tema y sintetizar a partir de estudios primarios (Kitchenham, Budgen & Brereton, 2016). Se eligió frente a una revisión narrativa tradicional porque sus procedimientos están definidos de antemano en un protocolo. Esto reduce el sesgo del investigador en la selección de fuentes y en la síntesis, y permite que otros repliquen el proceso. Los autores señalan que el término "revisión sistemática de literatura" se popularizó en ingeniería de software para evitar confusiones con las revisiones de código, pero que se trata del mismo método.

El proceso sigue las tres fases propuestas por Kitchenham et al. (2016), que se organizan en nueve actividades:

- Planificación: especificar las preguntas de investigación, desarrollar el protocolo y validarlo.
- Conducción: identificar la investigación relevante, seleccionar estudios primarios, evaluar su calidad, extraer datos y sintetizarlos.
- Documentación: reportar los resultados.

Esta RSL considera únicamente literatura blanca, es decir, trabajos publicados y revisados por pares (artículos de revista y de congresos). Quedan fuera la literatura gris, como informes técnicos, tesis, presentaciones y white papers. Este criterio es habitual en las revisiones del área, que suelen incluir solo artículos completos, revisados por pares y en inglés. Se eligió por dos razones: garantiza un nivel mínimo de calidad metodológica en los estudios incluidos y es coherente con las fuentes seleccionadas. Se reconoce como limitación el posible sesgo de publicación, ya que los resultados negativos o no significativos tienen menos probabilidad de publicarse.

En una RSL es importante cuantificar qué tan completa es la búsqueda. Para ello se empleó el enfoque de Quasi-Gold Standard propuesto por Zhang et al. (2011) y descrito por Kitchenham et al. (2016). Este enfoque se usa cuando no se tiene un conjunto grande de

estudios ya conocidos. Se construye una referencia a partir de una búsqueda manual restringida y se usa para medir el desempeño de la búsqueda automática. Los pasos que guían este metodo son los siguientes:

1. Identificación de fuentes de información y motores de búsqueda.
2. Establecimiento del QGS mediante una búsqueda manual.
3. Definición o extracción de cadenas de búsqueda.
4. Conducción de la búsqueda automatizada.
5. Evaluación del rendimiento de la búsqueda.

3.1. Identificar fuentes

Se definieron las bibliotecas digitales para la búsqueda automática, las cuales fueron IEEE Xplore, ACM DL, SpringerLink y ScienceDirect. Se escogieron las bibliotecas mencionadas debido a su relevancia y confiabilidad a la hora de buscar artículos respecto al tema de ingeniería de software y más recientemente de ciberseguridad además de cubrir el área de computo en general.

Zhang et al. (2011) mencionan que IEEE Xplore y ACM son de las bibliotecas más usadas para las revisiones sistemáticas en ingeniería de software, con un porcentaje de 92% para IEEE Xplore y 81% en ACM. Mientras SpringerLink y ScienceDirect alojan publicaciones que pueden aportar información relacionado a la ingeniería de software.

Las cuatro bibliotecas albergan publicaciones arbitradas, cumpliendo con el alcance definido. Además que las bibliotecas permiten exportar los metadatos en formatos como BibTeX o CSV, lo que facilita la gestión de referencias y la eliminación de duplicados.

3.2. Búsqueda manual

Se revisaron manualmente los títulos y resúmenes de todos los artículos de las fuentes elegidas, en el periodo de 2022 hasta el actual año 2026 que estén en el idioma inglés. Se aplicaron los criterios definidos previamente en el protocolo, es decir, que los artículos seleccionados puedan aportar información respondiendo al menos una sola de las preguntas de investigación propuestas.

Tabla 2.

Artículos encontrados mediante una fuente de información (venue).

Motor	**Venue**	**Artículos**
ACM	CCS '25: Proceedings of the 2025 ACM SIGSAC Conference on Computer and Communications Security - CCS '24: Proceedings of the 2024 on ACM SIGSAC Conference on Computer and Communications Security	• Chen, S., Zharmagambetov, A., Mahloujifar, S., Chaudhuri, K., Wagner, D., & Guo, C. (2025). SecAlign: Defending Against Prompt Injection with Preference Optimization. *CCS 2025 - Proceedings of the 2025 ACM SIGSAC Conference on Computer and Communications Security*, 2833–2847. https://doi.org/10.1145/3719027.3744836 • Shi, J., Yuan, Z., Liu, Y., Huang, Y., Zhou, P., Sun, L., & Gong, N. Z. (2024). Optimization-based Prompt Injection Attack to LLM-as-a-Judge. *CCS 2024 - Proceedings of the 2024 ACM SIGSAC Conference on Computer and Communications Security*, 660–674. https://doi.org/10.1145/3658644.3690291
ACM	AISec '25: Proceedings of the 18th ACM Workshop on Artificial Intelligence and Security	• Choudhary, S., Anshumaan, D., Palumbo, N., & Jha, S. (2025). How Not to Detect Prompt Injections with an LLM. *Proceedings of the 18th ACM Workshop on Artificial Intelligence and Security, AISec 2025*, 218–229. https://doi.org/10.1145/3733799.3762980 • Chen, S., Wang, Y., Carlini, N., Sitawarin, C., & Wagner, D. (2025). Defending Against Prompt Injection With a Few DefensiveTokens. *Proceedings of the 18th ACM Workshop on Artificial Intelligence and Security, AISec 2025*, 242–252. https://doi.org/10.1145/3733799.3762982
SpringerLink	Scientific Reports	• Srinivasan, J., Regi, S. A., Anbarasan, A. K., A, S., T, V., & Venu, S. (2026). Detection and analysis of prompt injection in indian multilingual large language models. *Scientific Reports*, *16*(1). https://doi.org/10.1038/s41598-026-43883-0 • Cai, Y. (2026). Prompt injection attacks on educational large language models for higher and

		vocational education. *Scientific Reports*, *16*(1). https://doi.org/10.1038/s41598-026-46563-1
ScienceDirect	Pattern Recognition 179 (2026) 113661 - Pattern Recognition 172 (2026) 112391	• Quan, G., Zhang, Z., Zhang, Y., Wang, W., Jing, J., & Xue, M. (2026). CM-PIUG: Cross-modal prompt injection unified modeling and game-theoretic defense strategies. *Pattern Recognition*, *179*. https://doi.org/10.1016/j.patcog.2026.113661 • Shi, X., Chen, S., Zhang, G., Wei, W., Li, Y., Fan, Z., & Liu, J. (2026). Jailbreak attack with multimodal virtual scenario hypnosis for vision-language models. *Pattern Recognition*, *172*. https://doi.org/10.1016/j.patcog.2025.112391

En la siguiente tabla se muestran las palabras clave (keywords) seleccionados a partir de las preguntas de investigación, esto con el objetivo de reducir la investigación y establecer un conjunto preliminar de términos que orienten la búsqueda que se realizará más adelante.

Tabla 3.

Conceptos y términos relacionados al contexto del problema de investigación de la revisión sistemática de literatura (RSL).

Palabra Clave (Keyword)	**Término relacionado**
LLM	Large Language Model, LLM
Prompt Injection	Prompt injection, Indirect Prompt Injection
Defense	Defenses, Mitigations, Detection

Se realizó una búsqueda manual en las bibliotecas elegidas, recabando un total de 31 estudios que responden al menos una pregunta de investigación. Los resultados se registraron en las siguientes tablas.

Tabla 4.

Artículos primarios relevantes recopilados mediante búsquedas manuales de IEEE Xplore.

Motor	Artículo
IEEE Xplore	Dao, A., Vangorder, R., Gebril, M., & Abdelhamid, S. (2026). A Comprehensive Assessment Tool for Prompt Injection Attacks in Large Language Models (LLMs). *2026 IEEE 5th International Conference on AI in Cybersecurity, ICAIC 2026*. https://doi.org/10.1109/ICAIC67076.2026.11395844
IEEE Xplore	Tortora, F., & de Angelis, V. (2025). An Experimental Evaluation of Prompt Injection Attacks on LLM-Based Content Moderation Systems. *International Conference on Social Networks Analysis, Management and Security, SNAMS*, (2025), 12–16. https://doi.org/10.1109/SNAMS67467.2025.11390931
IEEE Xplore	Ding, Z. H., & Labrinidis, A. (2025). DaMiT-SQL: Detecting and Mitigating Text-to-SQL Prompt Injection Attacks. *Proceedings - 2025 IEEE International Conference on Collaborative Advances in Software and Computing, CASCON 2025*, 641–646. https://doi.org/10.1109/CASCON66301.2025.00116
IEEE Xplore	Liu, Y., Jia, Y., Jia, J., Song, D., & Gong, N. Z. (2025). DataSentinel: A Game-Theoretic Detection of Prompt Injection Attacks. *Proceedings - IEEE Symposium on Security and Privacy*, 2190–2208. https://doi.org/10.1109/SP61157.2025.00250
IEEE Xplore	Kwon, H., & Pak, W. (2026). *Defending Against Prompt Injection Attacks Using Automatic System Prompt Engineering*. 1200–1203. https://doi.org/10.1109/icaiic68212.2026.11454261
IEEE Xplore	Starukh, K., & Koshelev, A. (2026). Evaluating a Multilayered Defense Against Prompt Injection in LLM-Augmented Educational Systems. *Proceedings - 2026 IEEE Ural-Siberian Conference on Biomedical Engineering, Radioelectronics and Information Technology, USBEREIT 2026*. https://doi.org/10.1109/USBEREIT70063.2026.11581043
IEEE Xplore	Nishith, P., & Panda, N. (2026). PRISM: Prompt Red-teaming and Injection Simulation for Models - A Scalable Framework for Evaluating LLM Robustness Against Malicious Prompts. *2026 International Conference on Smart Futuristic Technology, ICSFT 2026*. https://doi.org/10.1109/ICSFT66733.2026.11508065
IEEE Xplore	Joshi, T., Naik, V., Mistry, I., & Mangrulkar, R. (2025). Prevention of Prompt Injection Attacks Over Financial Applications Integrated with LLM. *Proceedings - 3rd International Conference on Advancement in Computation and Computer Technologies, InCACCT 2025*, 225–230. https://doi.org/10.1109/InCACCT65424.2025.11011372
IEEE	Wang, Y., Chen, S., Alkhudair, R., Alomair, B., & Wagner, D. (2026). Defending Against Prompt

Xplore	Injection with DataFilter. *2026 IEEE Conference on Secure and Trustworthy Machine Learning (SaTML)*, 139–157. https://doi.org/10.1109/SaTML68715.2026.00017
IEEE Xplore	Likitha, R., Dhanyashree, D. C., Lavanya, H. R., & Preeti. (2026). AI Prompt Injection Attack Tester. *2026 International Conference on Emerging Smart Computing and Informatics, ESCI 2026*. https://doi.org/10.1109/ESCI68015.2026.11493291

Tabla 5.

Artículos primarios relevantes recopilados mediante búsquedas manuales de ACM Digital Library.

Motor	**Artículo**
ACM	Yi, J., Xie, Y., Zhu, B., Kiciman, E., Sun, G., Xie, X., & Wu, F. (2025). Benchmarking and Defending against Indirect Prompt Injection Attacks on Large Language Models. *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, *1*, 1809–1820. https://doi.org/10.1145/3690624.3709179
ACM	Jia, Y., Shao, Z., Liu, Y., Jia, J., Song, D., & Gong, N. (2026). A Critical Evaluation of Defenses against Prompt Injection Attacks: [Dataset/Tool Paper]. *Proceedings of ACM Symposium on Access Control Models and Technologies, SACMAT*, 265–270. https://doi.org/10.1145/3750555.3811884
ACM	Pedro, R., Coimbra, M. E., Castro, D., Carreira, P., & Santos, N. (n.d.). *Prompt-to-SQL Injections in LLM-Integrated Web Applications: Risks and Defenses*. https://doi.org/10.1109/ICSE55347.2025.00007
ACM	Jaiswal, P., Pratap, A., Saraswati, S., Kasyap, H., & Tripathy, S. (2026). Analysis of LLMs Against Prompt Injection and Jailbreak Attacks. *LM-SHIELD 2026 - Workshop on Privacy in Large Language Models (LLM) and Natural Language Processing (NLP)*, 10–21. https://doi.org/10.1145/3803628.3807972
ACM	Son, Y., Lee, C., Shin, D., Lee, B., Hong, S., & Son, S. (2026). AgentBreaker: Evaluating Context-Aware Indirect Prompt Injection Risks in Modern Web Agents. *Proceedings of the ACM on Software Engineering*, *3*(ISSTA), 1696–1717. https://doi.org/10.1145/3832165
ACM	Wang, L., Ying, Z., Zhang, T., Liang, S., Hu, S., Zhang, M., Liu, A., & Liu, X. (2025). Manipulating Multimodal Agents via Cross-Modal Prompt Injection. *MM 2025 - Proceedings of the 33rd ACM International Conference on Multimedia, Co-Located with MM 2025*, 10955–10964. https://doi.org/10.1145/3746027.3755211

Tabla 6.

Artículos primarios relevantes recopilados mediante búsquedas manuales de SpringerLink.

Motor	Artículo
SpringerLink	Kiourkos, A., Cánovas Izquierdo, J. L., & Clarisó, R. (2026). Automatic Security Testing of System Prompts Against Prompt Injection Attacks. *Lecture Notes in Business Information Processing*, *585 LNBIP*, 193–209. https://doi.org/10.1007/978-3-032-26836-5_12
SpringerLink	Huang, S., & Lee, S. J. (2026). Bringing the Dual-LLM pattern to practice in Google ADK for deterministic AI agent security against prompt injection. *Artificial Life and Robotics*. https://doi.org/10.1007/s10015-026-01152-3
SpringerLink	Liao, W., & Li, L. (2027). Defense Against Prompt Injection Attacks via Intention Emphasis. *Communications in Computer and Information Science*, *2910 CCIS*, 432–444. https://doi.org/10.1007/978-981-92-0291-1_30
SpringerLink	Humble, N. (2026). Ethical Implications of Prompt Injection in AI-mediated Grading: An Adversarial Red-Team Evaluation. *Journal of Academic Ethics*, *24*(3). https://doi.org/10.1007/s10805-026-09758-9
SpringerLink	Torrielli, F., Locci, S., Rapp, A., & di Caro, L. (2026). Exploiting large language models in peer review: indirect prompt injection attacks and integrity probes. *Scientometrics*, *131*(7), 4889–4951. https://doi.org/10.1007/s11192-026-05695-x
SpringerLink	Torrielli, F., Locci, S., Rapp, A., & di Caro, L. (2026). Exploiting large language models in peer review: indirect prompt injection attacks and integrity probes. *Scientometrics*, *131*(7), 4889–4951. https://doi.org/10.1007/s11192-026-05695-x
SpringerLink	Milani, A., Franzoni, V., & Florindi, E. (2026). Indirect prompt injection in large language models. *Neural Computing and Applications*, *38*(13). https://doi.org/10.1007/s00521-026-12266-x
SpringerLink	Lee, D., Tiwari, M., & Miranda, B. (2026). Prompt Infection: LLM-to-LLM Prompt Injection within Multi-agent Systems. *Lecture Notes in Computer Science*, *16232 LNCS*, 511–520. https://doi.org/10.1007/978-3-032-16092-8_28

Tabla 7.

Artículos primarios relevantes recopilados mediante búsquedas manuales de ScienceDirect.

Motor	**Artículo**

ScienceDirect	Pokhrel, K., Sanin, C., Md. Kowssar Hossain, S., Islam, M. R., & Szczerbicki, E. (2024). An Adversarial Machine Learning Approach on Securing Large Language Model with Vigil, an Open-Source Initiative. *Procedia Computer Science*, *246*(C), 686–695. https://doi.org/10.1016/j.procs.2024.09.486
ScienceDirect	Bahgat Elserwy, T., & El-Demerdash, B. E. (2026). *Automated security-centric refactoring of PowerShell commands using large language models: A Python-based framework for cross-language automation*. https://doi.org/10.1016/j.eij.2026.101029
ScienceDirect	Geng, T., Qu, Y., & Wong, W. E. (2026). A white-box prompt injection attack on embodied AI agents driven by large language models the. *Journal of Systems and Software*, *235*. https://doi.org/10.1016/j.jss.2026.112782
ScienceDirect	Kim, D., Kim, D., & Min, M. (2026). Evidence-borne prompt injection in LLM-assisted textual evidence triage. *Forensic Science International: Digital Investigation*, *58*. https://doi.org/10.1016/j.fsidi.2026.302187
ScienceDirect	Herrador, M., & Rehberger, J. (2026). SpAIware: Uncovering a novel artificial intelligence attack vector through persistent memory in LLM applications and agents. *Future Generation Computer Systems*, *174*. https://doi.org/10.1016/j.future.2025.107994
ScienceDirect	Kurniawan, A., & Chandra, M. B. (2025). Simulation of prompt injection attacks on generative pre-trained transformers models. *Procedia Computer Science*, *269*, 400–410. https://doi.org/10.1016/j.procs.2025.08.292
ScienceDirect	Kurniawan, A., & Chandra, M. B. (2025). Simulation of prompt injection attacks on generative pre-trained transformers models. *Procedia Computer Science*, *269*, 400–410. https://doi.org/10.1016/j.procs.2025.08.292

Los artículos incluidos forman el QGS, con un total de 39 estudios considerando los 8 artículos obtenidos mediante venues y 31 artículos usando búsqueda manual.

3.3. Conceptos y términos

Después de la selección manual de estudios, el conjunto se sometió a un análisis para la extracción de keywords por medio de un conteo de keywords mediante el uso de scripts en el lenguaje de python, con el objetivo de realizar una extracción objetiva de términos de búsqueda, como se recomienda en el trabajo de Zhang et al. (2011).

Tabla 8.

Conteo de keywords por motor de busqueda.

Motor de búsqueda	Keywords	Conteo
IEEE	prompt	647
	llm	506
	injection	351
	attack	323
	detection	304
	defense	132
	prompt injection	283
ACM	prompt	788
	llm	782
	attacks	519
	injection	458
	prompt injection	361
	injection attacks	138
	defense	231
	detection	288
SpringerLink	prompt	855
	injection	609
	llm	407
	attack	368
	defense	126
	detection	133

	evaluation	183
	prompt injection	455
	injection attacks	114
ScienceDirect	attack	555
	prompt	400
	injection	287
	security	432
	attacks	329
	llm	242
	prompt injection	220
	defense	210

Ya con el conteo de palabras completado, se puede observar una tendencia en términos específicos como lo son “LLM”, “prompt injection” o “defense”. En base a estos resultados se fueron registrando los conceptos y términos principales para la posterior creación de las cadenas.

Tabla 9.

Recopilación de conceptos y terminos asociados para la creación de cadenas de busqueda.

Concepto	**Término relacionado**
Large Language Model	LLM LLM-based system
Ataque	Prompt Injection Indirect Prompt Injection Injection Attack
Defensa	Defense

	Detection Mitigation Prevention Attack detection Security Evaluation

3.4. Creación de cadenas y validación de cadenas

Las cadenas de búsqueda se derivaron de dos fuentes: las preguntas de investigación y los términos más frecuentes de los estudios del QGS. Siguiendo a Kitchenham et al. (2016), el proceso fue el siguiente:

1. Identificación de conceptos: Se extrajeron los conceptos y términos centrales de las preguntas de investigación.
2. Análisis del QGS: Se revisaron los términos recurrentes en los estudios del QGS y se contrastaron con los extraídos de las preguntas.
3. Sinónimos y variantes: Se agregaron sinónimos y variantes de los términos clave.
4. Prueba preliminar: Las cadenas se probaron primero en una biblioteca digital y se comprobó qué porcentaje de los estudios conocidos recuperaban.

Las cadenas se redactaron de forma general, evitando términos propios de un artículo en particular, para no sesgar la búsqueda hacia los estudios del QGS. También se mantuvieron simples. Kitchenham et al. señalan que las cadenas complejas suelen devolver muchos falsos positivos en ingeniería de software, y que las bibliotecas digitales limitan la complejidad de las cadenas de forma distinta. Por eso, las cadenas se adaptaron a la sintaxis y a las restricciones de IEEE Xplore, ACM DL, SpringerLink y ScienceDirect.

El desempeño de las cadenas se evaluó con dos métricas de recuperación de información (Kitchenham et al., 2016; Zhang et al., 2011), calculadas respecto al QGS:

$$Cuasi - sensibilidad = \frac{R_{encontrados}}{R_{QGS}}$$

$$Cuasi - precisión = \frac{R_{encontrados}}{N_{total}}$$

Tabla 10.

Presentación de las variables para calcular las metricas de evaluación de una cadena de busqueda.

Variable	Definición
R_QGS	Total de estudios relevantes del QGS, es decir, los hallados en la búsqueda manual
R_encontrados	Estudios del QGS recuperados por la búsqueda automática en las mismas fuentes y periodo de la búsqueda manual
N_total	Total de estudios devueltos por la búsqueda automática

- Cuasi-sensibilidad (quasi-recall). Mide la completitud de la búsqueda, es decir, qué proporción de los estudios relevantes conocidos se recupera. Es la métrica principal para decidir si la cadena es aceptable. Se llama "cuasi" porque el denominador es el QGS y no el total real de estudios relevantes, que es desconocido.
- Cuasi-precisión (quasi-precisión). Mide qué proporción de lo recuperado es relevante. Una precisión baja implica que los revisores deben leer muchos artículos irrelevantes. Por eso, aumentar la sensibilidad con cadenas más amplias suele reducirla.

Tabla 11.

Evaluación de las cadenas candidatas para IEEE Xplore.

Cadena	N_total	R_encontrados	R_QGS	Sensibilidad	Precisión

("large language model" OR LLM OR "LLM-based system") AND ("prompt injection" OR "indirect prompt injection")	260	9	10	0.9	0.034
("large language model" OR LLM OR "LLM-based system") AND ("prompt injection" OR "indirect prompt injection") AND (defense OR defence OR detection OR mitigation OR prevention OR "attack detection")	198	9	10	0.9	0.045
("large language model" OR LLM OR "LLM-based system") AND ("prompt injection" OR "indirect prompt injection" OR “prompt injection attack”) AND (defense OR detection OR mitigation OR prevention OR "attack detection")	253	9	10	0.9	0.035
("large language model" OR LLM OR "LLM-based system") AND ("prompt injection" OR "indirect prompt injection") AND (defense OR detection OR mitigation OR prevention OR "attack detection")	206	9	10	0.9	0.043

Tabla 12.

Evaluación de las cadenas candidatas para ACM Digital Library.

Cadena	**N_total**	**R_encontrados**	**R_QGS**	**Sensibilidad**	**Precisión**
("large language model" OR LLM OR "LLM-based system") AND ("prompt injection" OR "indirect prompt injection")	667	10	10	1	0.014

(LLM OR "large language model" OR "LLM agent") AND ("prompt injection" OR "indirect prompt injection") AND (defense OR defence OR defenses OR detection OR mitigation OR security)	658	10	10	1	0.015
("large language model" OR LLM OR "LLM-based system") AND ("prompt injection" OR "indirect prompt injection" OR “prompt injection attack”) AND (defense OR detection OR mitigation OR prevention OR "attack detection")	679	10	10	1	0.014
("large language model" OR LLM OR "LLM-based system") AND ("prompt injection" OR "indirect prompt injection") AND (defense OR detection OR mitigation OR prevention OR "attack detection")	679	10	10	1	0.014

Tabla 13.

Evaluación de las cadenas candidatas para SpringerLink.

Cadena	**N_total**	**R_encontrados**	**R_QGS**	**Sensibilidad**	**Precisión**
("large language model" OR LLM OR "LLM-based system") AND ("prompt injection" OR "indirect prompt injection")	862	10	10	1	0.011
("large language model" OR LLM OR "LLM-based system") AND ("prompt injection" OR "indirect prompt injection") AND (defense OR defence OR	716	10	10	1	0.013

detection OR mitigation OR prevention OR "attack detection")					
("large language model" OR LLM OR "LLM-based system") AND ("prompt injection" OR "indirect prompt injection" OR “prompt injection attack”) AND (defense OR detection OR mitigation OR prevention OR "attack detection")	1006	10	10	1	0.009
("large language model" OR LLM OR "LLM-based system") AND ("prompt injection" OR "indirect prompt injection") AND (defense OR detection OR mitigation OR prevention OR "attack detection")	712	10	10	1	0.014

Tabla 14.

Evaluación de las cadenas candidatas para ScienceDirect.

Cadena	**N_total**	**R_encontrados**	**R_QGS**	**Sensibilidad**	**Precisión**
("large language model" OR LLM OR "LLM-based system") AND ("prompt injection" OR "indirect prompt injection")	490	9	9	1	0.018
("large language model" OR LLM OR "LLM-based system") AND ("prompt injection" OR "indirect prompt injection") AND (defense OR detection OR mitigation)	455	9	9	1	0.019
(LLM OR "large language model") AND ("prompt injection" OR "indirect prompt	469	9	9	1	0.019

injection") AND (defense OR detection OR mitigation OR security)					
(LLM OR "large language model" OR "LLM-based system") AND ("prompt injection" OR "indirect prompt injection") AND (defense OR detection OR mitigation OR security)	469	9	9	1	0.019

3.4.1. Cadenas finales

Con base en la evaluación de las cadenas propuestas para cada motor de búsqueda, se cotejaron aquellas cadenas con el rendimiento más favorable y que usaran terminos generales. Quedando con las siguientes cadenas finales.

Tabla 15.

Cadenas finales para la búsqueda automatizada.

Motor	**Cadena elegida**
IEEE, ACM, SpringerLink	("large language model" OR LLM OR "LLM-based system") AND ("prompt injection" OR "indirect prompt injection") AND (defense OR detection OR mitigation OR prevention OR "attack detection")
ScienceDirect	("large language model" OR LLM OR "LLM-based system") AND ("prompt injection" OR "indirect prompt injection") AND (defense OR detection OR mitigation)

Dado que ScienceDirect presenta un límite en el uso de operadores lógicos, con un máximo de 8 operadores, fue necesario ajustar la cadena reduciendo los operadores manteniendo la simplicidad de la cadena.

4. Selección de estudios primarios

En este apartado se establecieron los criterios de inclusión y exclusión, los cuales ayudaron a acotar el conjunto de estudios obtenidos por la cadena de búsqueda seleccionada.

4.1. Criterios de inclusión

Tabla 16.

Criterios de inclusión para la selección de estudios primarios.

Identificador	**Criterio**
Ci1	Se recabarán y analizarán exclusivamente estudios escritos en el idioma inglés.
Ci2	Se consideran estudios publicados entre el 1 de enero de 2022 y la fecha de cierre de las búsquedas durante 2026.
Ci3	El título del estudio presenta indicios de responder al menos una pregunta de investigación.
Ci4	El abstract del estudio presenta indicios de responder al menos una pregunta de investigación.
Ci5	El artículo responde al menos una pregunta de investigación

4.2. Criterios de exclusión

Tabla 17.

Criterios de inclusión para la selección de estudios primarios

Identificador	Criterio
Ce1	Artículos que no se puedan acceder a través de la biblioteca de la universidad.
Ce2	Se descartan revisiones sistemáticas, revisiones de literatura, mapeos sistemáticos y otros estudios secundarios.
Ce3	Se descartan artículos duplicados.
Ce4	Publicaciones que no correspondan a artículos de revistas o trabajos publicados en congresos y workshops.

4.3. Procedimiento de selección de estudios primarios

Para realizar la selección de los estudios primarios, se estableció un procedimiento sistemático compuesto por seis etapas. Estas permiten aplicar progresivamente los criterios de inclusión y exclusión definidos, con el propósito de identificar las publicaciones que aporten información pertinente para responder las preguntas de investigación.

1. Recuperación de estudios: Se recopilarán los resultados obtenidos mediante la ejecución de las cadenas de búsqueda en las bibliotecas digitales seleccionadas. Los registros recuperados se organizarán en una hoja de cálculo para facilitar su procesamiento y seguimiento durante las siguientes etapas.
2. Eliminación de duplicados: Se identificarán y eliminarán los registros que correspondan a una misma publicación, aplicando el criterio de exclusión Ce3.
3. Filtrado inicial: Se revisarán los metadatos de las publicaciones para verificar el cumplimiento de los criterios relacionados con el idioma (Ci1), el periodo de publicación (Ci2) y la disponibilidad del texto completo mediante los recursos de acceso institucional (Ce1). Los registros que no cumplan con estas condiciones serán descartados.
4. Revisión de las características de las publicaciones: Se examinará el tipo de documento y su naturaleza académica para aplicar los criterios de exclusión Ce2 y Ce4. En esta etapa se descartarán las revisiones y otros estudios secundarios, así como las publicaciones que no correspondan a artículos de revistas o trabajos publicados en congresos y workshops.
5. Evaluación del título y resumen: Se realizará una lectura exploratoria del título y el resumen de cada publicación restante, con el propósito de identificar indicios de pertinencia respecto a las preguntas de investigación. Para ello, se aplicarán los criterios de inclusión Ci3 y Ci4. Los estudios que no presenten indicios de aportar información relevante para responder alguna de las preguntas de investigación serán excluidos.
6. Evaluación del texto completo: Finalmente, se realizará una lectura completa de los estudios preseleccionados para determinar si su contenido aporta información pertinente para responder al menos una pregunta de investigación. En esta etapa se

aplicará el criterio Ci5 y se establecerá el conjunto definitivo de estudios primarios que formarán parte de la revisión sistemática.

Durante el procedimiento se registrará la cantidad de publicaciones que continúen en cada etapa, así como los motivos de exclusión correspondientes. Esto permitirá documentar el proceso de selección y presentar de manera transparente la transición desde los resultados recuperados inicialmente hasta el conjunto final de estudios primarios.

5. Extracción de datos

En este apartado se establecieron los datos que fueron extraídos de los estudios primarios, así como los mecanismos por lo que se recabó esta información. Kitchenham et al. (2015) señalan que los detalles de publicación y la información necesaria para responder las preguntas de investigación son los datos imprescindibles que deben sustraerse (p. 51).

Para llevar a cabo este proceso, se diseñó un formulario de extracción de datos mediante una hoja de cálculo. El formulario se estructura en dos secciones: la primera comprende los datos bibliográficos de cada estudio primario, mientras que la segunda contiene campos específicos para recopilar la información correspondiente a cada una de las siete preguntas de investigación (Q1–Q7).

Dato	**Descripción**
Identificador	Identificador único para cada estudio
Título	Título del estudio primario; en correspondencia con Ci3
Autores	Nombre y apellido del autor del estudio primario.
Año publicación	En correspondencia con Ci2
Tipo de publicación	En correspondencia con Ce2
Venue	Nombre de la fuente de información que publicó el estudio primario.
DOI	Identificador de objeto digital (DOI, por sus siglas en inglés) asignado al estudio primario.
Abstract	Resumen del estudio primario; en correspondencia con Ci4

Preguntas de investigación relacionadas	Pregunta de investigación que motiva esta revisión.
Tipos de inyección de prompt	Tipos de ataques de inyección de prompt a nivel de aplicación identificados en el estudio. P1
Medidas de seguridad	Medidas de seguridad a nivel de aplicación propuestas para reducir los ataques de inyección de prompt. P2
Categorías de las medidas	Categoría de cada medida de seguridad de acuerdo con su punto de intervención dentro del sistema basado en LLM. P3
Escenarios de implementación	Escenarios, contextos o entornos en los que se implementaron las medidas de seguridad. P4
Evaluación de efectividad	Métodos, métricas, conjuntos de datos y experimentos empleados para evaluar la efectividad de las medidas. P5
Limitaciones y retos	Limitaciones identificadas y retos pendientes de las medidas de seguridad analizadas. P6
Trabajo futuro	Líneas de investigación y propuestas de trabajo futuro señaladas por los autores. P7

La extracción se realizará mediante la revisión del contenido de cada estudio primario, considerando principalmente sus secciones de metodología, resultados, discusión y conclusiones. Asimismo, se registran las páginas o secciones correspondientes a la información recopilada, con el propósito de facilitar su verificación y mantener la trazabilidad de los datos.

6. Estrategia para la síntesis de datos

La estrategia utilizada en esta revisión sistemática es la síntesis narrativa, cuyo fundamento se encuentra en la guía propuesta por Popay et al. (2006). Este enfoque establece cuatro actividades para organizar, analizar e interpretar los hallazgos de los estudios primarios: desarrollo de una teoría, desarrollo de una síntesis preliminar, exploración de las relaciones dentro y entre los estudios, y evaluación de la robustez del producto de la síntesis.

Debido a que esta investigación busca identificar y analizar los tipos de ataques de inyección de prompt, así como las medidas de seguridad propuestas para mitigarlos a nivel

de aplicación en sistemas basados en LLM, se seleccionaron técnicas que permitan organizar la información, identificar patrones y comparar los resultados de los estudios. A continuación, se describen las actividades y técnicas que se emplearán.

6.1. Desarrollo de una teoría

En esta actividad se establece el contexto de la investigación y se definen las preguntas que orientan el proceso de revisión. Estas preguntas delimitan los aspectos que serán examinados en los estudios primarios y, por consiguiente, guían las etapas de extracción, síntesis y análisis de los datos.

En esta revisión, las preguntas de investigación se enfocan en identificar los tipos de ataques de inyección de prompt dirigidos a sistemas basados en LLM, reconocer las medidas de seguridad a nivel de aplicación propuestas en la literatura y analizar las categorías en las que pueden agruparse dichas medidas. De esta manera, se establece una estructura temática que permitirá organizar los hallazgos de acuerdo con los objetivos de la investigación.

6.2. Desarrollo de una síntesis preliminar

Para esta actividad se seleccionaron dos técnicas que permitirán organizar y describir los datos extraídos de los estudios primarios:

1. Tabulación de datos. Consiste en organizar la información recopilada de cada estudio en tablas, con el propósito de facilitar su consulta y comparación. En esta revisión, se registran los datos bibliográficos de las publicaciones y los hallazgos relacionados con cada pregunta de investigación. Entre estos se consideran los tipos de ataques identificados, las medidas de seguridad propuestas, su funcionamiento y el contexto de aplicación. Esta organización permitirá reconocer características comunes y diferencias iniciales entre los estudios.
2. Descripción textual. Consiste en elaborar una descripción breve de los hallazgos reportados en cada estudio primario. Esta técnica complementará la tabulación, ya que permitirá explicar el propósito de las medidas de seguridad, su mecanismo de funcionamiento y los resultados o limitaciones señalados por sus autores.

Asimismo, servirá como punto de partida para la comparación e interpretación de los hallazgos en la siguiente actividad.

6.3. Exploración de las relaciones dentro y entre estudios

En esta actividad se analizarán las relaciones entre las características de cada estudio y sus respectivos hallazgos, así como las similitudes y diferencias que existan entre los resultados de los distintos estudios primarios. El propósito es identificar patrones que permitan comprender cómo se abordan los ataques de inyección de prompt y qué medidas de seguridad se han propuesto para reducirlos.

Para ello, se emplearán las siguientes técnicas:

1. Comparación de hallazgos. Se contrastarán los tipos de ataques identificados y las medidas de seguridad propuestas en los estudios primarios. En el caso de las medidas, se considerarán aspectos como su objetivo, mecanismo de funcionamiento, punto de aplicación dentro del sistema, tipos de ataques que buscan mitigar y limitaciones reportadas. Esta comparación permitirá identificar coincidencias, diferencias y posibles aspectos que no hayan sido suficientemente abordados en la literatura.
2. Desarrollo de modelos conceptuales o mapas de conceptos. Se elaborará una representación visual de las relaciones identificadas entre los tipos de ataques y las medidas de seguridad. Asimismo, se buscará organizar estas medidas en categorías de acuerdo con sus características y mecanismos de funcionamiento. Este recurso facilitará la interpretación de los hallazgos y servirá como apoyo para estructurar la síntesis narrativa.

Los resultados de esta actividad se presentarán mediante tablas comparativas y una representación conceptual que muestre la clasificación de las medidas de seguridad identificadas.

6.4. Evaluación de la robustez del producto de la síntesis

Finalmente, se evaluará la solidez de los resultados obtenidos durante la síntesis, considerando la cantidad y calidad de los estudios primarios, así como el tipo de evidencia

que respalda sus hallazgos. Para ello, se tendrá en cuenta si las medidas de seguridad fueron evaluadas experimentalmente, si se presentan como propuestas conceptuales o si cuentan con resultados que permitan valorar su funcionamiento. La técnica seleccionada para esta actividad es:

- Reflexión crítica sobre el proceso de síntesis. Consiste en revisar el procedimiento utilizado para organizar, comparar e interpretar los hallazgos, identificando posibles limitaciones o dificultades durante el análisis. En esta investigación, se considerará la disponibilidad y el nivel de detalle de la información reportada en los estudios, las diferencias entre sus contextos de evaluación y la solidez de la evidencia presentada. Esto permitirá establecer los alcances y limitaciones de las conclusiones obtenidas, evitando atribuir el mismo nivel de respaldo a propuestas que no cuentan con una evaluación empírica y a aquellas que sí presentan resultados experimentales.

De esta manera, la síntesis narrativa permitirá integrar e interpretar los hallazgos de los estudios primarios para responder las preguntas de investigación, sin limitar el análisis a la enumeración o el conteo de las medidas identificadas.

7. Limitaciones

La presente revisión sistemática establece las siguientes limitaciones, derivadas de las decisiones tomadas para delimitar su alcance:

1. Tipo de literatura considerada: Se incluirán únicamente publicaciones pertenecientes a la literatura blanca, es decir, documentos académicos que hayan pasado por un proceso de revisión y aprobación editorial o científica, como artículos publicados en revistas y conferencias. Por lo tanto, se excluirán fuentes de literatura gris, tales como tesis, informes técnicos, documentos institucionales, prepublicaciones y publicaciones que no hayan pasado por un proceso formal de revisión. En consecuencia, los hallazgos estarán limitados a las investigaciones difundidas mediante los canales de publicación seleccionados.

2. Disponibilidad de las publicaciones: Se considerarán únicamente los artículos cuyo texto completo puede consultarse mediante el acceso institucional disponible a través de las bibliotecas y bases de datos seleccionadas. Por esta razón, podrán quedar excluidos estudios potencialmente relevantes cuyo contenido completo no esté disponible bajo dichas condiciones. Esto implica que la revisión no necesariamente abarca la totalidad de las investigaciones existentes sobre el tema.
3. Delimitación temática: La revisión se centrará exclusivamente en las medidas de seguridad propuestas para mitigar ataques de inyección de prompt a nivel de aplicación en sistemas basados en modelos de lenguaje de gran tamaño (LLM). Se excluirán investigaciones que aborden la seguridad de estos modelos desde otras perspectivas, como el entrenamiento, el ajuste o la modificación de la arquitectura interna del modelo.
4. Alcance de las conclusiones sobre las medidas de seguridad: El análisis se limitará a las características, mecanismos de funcionamiento, objetivos y resultados reportados para las medidas de seguridad identificadas en los estudios seleccionados. Por consiguiente, la revisión no pretende determinar cuál es la medida más eficaz en términos generales, establecer una clasificación universal de su rendimiento ni garantizar su efectividad en todos los sistemas basados en LLM. Las conclusiones estarán circunscritas a la evidencia encontrada y a los contextos en los que las medidas hayan sido estudiadas y evaluadas.
5. Alcance de los tipos de ataques identificados: Se considerarán los ataques de inyección de prompt que puedan relacionarse con el funcionamiento de los sistemas basados en LLM a nivel de aplicación. Por lo tanto, no se pretende elaborar una taxonomía general de todas las amenazas de seguridad que afectan a los LLM, sino identificar y organizar aquellas modalidades de inyección de prompt que sean pertinentes para el objeto de estudio.

8. Informe

1. Resumen
2. Introducción
3. Antecedentes

4. Metodología de la revisión
    4.1. Preguntas de investigación
    4.2. Estrategia de búsqueda
    4.3. Selección de estudios primarios
    4.4. Extracción de datos
    4.5. Estrategia para la síntesis de datos
5. Conducción de la revisión
    5.1. Ejecución de las búsquedas
    5.2. Aplicación del procedimiento de selección de estudios primarios
    5.3. Proceso de extracción de datos
    5.4. Modificaciones respecto al protocolo de revisión
6. Resultados de la revisión
    6.1. Resultados de las búsquedas
    6.2. Resultados de la selección de estudios primarios
    6.3. Caracterización de los estudios seleccionados
7. Análisis y síntesis de resultados
    7.1. Metodologías y procedimientos
    7.2. Contextos de aplicación
    7.3. Etapas y actividades
    7.4. Herramientas
    7.5. Métricas e indicadores
    7.6. Consideraciones, limitaciones y retos reportados
8. Discusión
    8.1. Interpretación de los hallazgos
    8.2. Limitaciones y amenazas a la validez de la revisión
9. Conclusiones
10. Referencias
11. Anexos

9. Gestión de la revisión

El cronograma contempla las actividades para el desarrollo de la revisión sistemática, desde octubre de 2026 hasta la finalización del séptimo semestre, prevista para la segunda semana de diciembre del mismo año.

Mes	**Octubre**				**Noviembre**				**Diciembre**	
Semana	**1°**	**2°**	**3°**	**4°**	**1°**	**2°**	**3°**	**4°**	**1°**	**2°**
Desarrollo del protocolo de la RSL										
Selección de estudios										
Extracción de datos										
Síntesis										
Redacción del reporte										

Para gestionar y organizar las actividades de la revisión sistemática se utilizaron distintas herramientas de apoyo, seleccionadas de acuerdo con las necesidades de cada etapa del proceso.

En primer lugar, se emplearon hojas de cálculo de “LibreOffice Calc” para registrar y organizar los conceptos y términos relacionados con el tema de investigación, así como para documentar las cadenas de búsqueda diseñadas para cada biblioteca digital. Asimismo, se utilizaron para registrar los resultados de las búsquedas y calcular las métricas

correspondientes durante el proceso de evaluación y selección de las cadenas. Estas hojas de cálculo también servirán como herramienta para registrar los datos extraídos de los estudios primarios y organizar los resultados de la síntesis.

Por otra parte, se desarrollaron y utilizaron scripts en Python para realizar el conteo de palabras presentes en los estudios seleccionados como muestra durante la construcción de las cadenas de búsqueda. Esta actividad permitió identificar los términos con mayor frecuencia y utilizarlos como apoyo para la formulación y el ajuste de las cadenas candidatas.

Finalmente, se utilizó Mendeley como gestor de referencias bibliográficas, con el propósito de organizar las publicaciones consultadas, mantener un registro de sus datos bibliográficos y facilitar la incorporación de citas y referencias en la elaboración del reporte.

Referencias

1. Damacena Duarte, J., Cândido, G. D., de Britto Filho, J. R. A., Souza Neto, J., da Costa, E. J., da Costa, J. P. J., & Peotta De Melo, L. (2026). A Systematic Review of Prompt Injection Attacks on Large Language Models: Trends, Taxonomy, Evaluation, Defenses, and Opportunities. In IEEE Access (Vol. 14, pp. 12875–12899). Institute of Electrical and Electronics Engineers Inc. https://doi.org/10.1109/ACCESS.2026.3656849
2. Geng, T., Xu, Z., Qu, Y., & Wong, W. E. (2026). Prompt Injection Attacks on Large Language Models: A Survey of Attack Methods, Root Causes, and Defense Strategies. In Computers, Materials and Continua (Vol. 87, Issue 1). Tech Science Press. https://doi.org/10.32604/cmc.2025.074081
3. Greshake, K., Abdelnabi, S., Mishra, S., Endres, C., Holz, T., & Fritz, M. (2023). Not what you've signed up for: Compromising Real-World LLM-Integrated Applications with Indirect Prompt Injection. http://arxiv.org/abs/2302.12173
4. Kitchenham et al. (2015). Evidence-Based Software Engineering and Systematic Reviews. Chapman & Hall/CRC.
5. Mathew, E. S. (2025). Enhancing Security in Large Language Models: A Comprehensive Review of Prompt Injection Attacks and Defenses. *Journal on Artificial Intelligence*, *7*(1), 347–363. https://doi.org/10.32604/jai.2025.069841

6. Popay, J., Arai, L., Rodgers, M., & Britten, N. (2006). *Guidance on the conduct of narrative synthesis in systematic reviews: A product from the ESRC Methods Programme*. https://doi.org/10.13140/2.1.1018.4643
7. Vassilev, A. (2025). *Adversarial Machine Learning:* https://doi.org/10.6028/NIST.AI.100-2e2025
8. Wang, P., Li, X., Xiang, C., Zhang, J., Li, Y., Zhang, L., Wang, X., & Tian, Y. (2026). *The Landscape of Prompt Injection Threats in LLM Agents: From Taxonomy to Analysis*. http://arxiv.org/abs/2602.10453
9. ¿Qué son los LLM? | IBM. (2026, August 16). https://www.ibm.com/mx-es/think/topics/largelanguage-models
10. Zhang, H., Babar, M. A., & Tell, P. (2011). Identifying relevant studies in software engineering. Information and Software Technology, 53(6), 625–637. https://doi.org/10.1016/j.infsof.2010.12.0

“Lis de Veracruz: Arte, Ciencia, Luz”

www.uv.mx

