

Estado del arte de las medidas de seguridad a nivel de aplicación en el contexto de ataques de inyección de prompt dirigidos a sistemas basados en LLM – Monografía

En la actualidad, con el aumento de sistemas digitales en distintas áreas de la vida cotidiana, como el transporte, el comercio, la educación, la energía e incluso la salud, ha provocado que la ciberseguridad tome mayor relevancia. Las organizaciones no solo buscan proteger sus sistemas frente a amenazas actuales, sino también anticiparse a futuros riesgos, cumplir con normativas y reducir las consecuencias de posibles incidentes o brechas de seguridad. En base a esto, la ciberseguridad puede entenderse como el área encargada de diseñar, implementar y evaluar prácticas y/o herramientas destinados a proteger la información, el software, el hardware y los servicios digitales frente a accesos no autorizados, manipulación, interrupciones o pérdida de datos.

De manera paralela al desarrollo de la ciberseguridad, los modelos grandes de lenguaje, conocidos como LLM por sus siglas en inglés, han adquirido una presencia cada vez mayor en aplicaciones digitales. Un LLM es un tipo de inteligencia artificial capaz de procesar instrucciones en lenguaje natural y generar respuestas comprensibles para los humanos. Estos modelos suelen utilizarse para responder preguntas, resumir documentos, generar código o interactuar con otros sistemas. Sin embargo, cuando un LLM se integra dentro de una aplicación más amplia, ya no se habla únicamente del modelo, sino de un sistema basado en LLM. Un sistema basado en LLM puede entenderse como una aplicación o plataforma que utiliza un modelo grande de lenguaje como componente principal, pero que además puede integrar otros elementos, como entradas del usuario, documentos externos o bases de datos. Por ejemplo, un chatbot que responde con base en documentos internos puede considerarse un sistema basado en LLM.

Una de las amenazas asociadas con los LLM es la inyección de prompt, o prompt injection. Ocurre cuando un usuario o atacante introduce instrucciones maliciosas dentro de una entrada, documento, página web o fuente externa procesada por el sistema, con el objetivo de alterar su comportamiento. Por ejemplo, una instrucción maliciosa podría intentar que el modelo ignore reglas previas, revele información sensible, genere una respuesta manipulada o ejecute una acción no autorizada. Esto se vuelve más preocupante cuando el sistema procesa información externa, ya que el usuario podría no saber que un documento, página web o salida de herramienta contiene instrucciones ocultas.

Por esta razón, mi investigación se enfoca en el análisis del estado del arte de las medidas de seguridad a nivel de aplicación contra ataques de inyección de prompt dirigidos a sistemas basados en LLM, es decir, el trabajo no busca modificar o ajustar internamente un modelo de inteligencia artificial, sino revisar las medidas que pueden aplicarse alrededor del sistema que lo integra. La importancia de este tema radica en que los sistemas basados en LLM están comenzando a utilizarse en diversos contextos donde pueden procesar información sensible, interactuar con fuentes externas o apoyar decisiones técnicas. Si no existen controles adecuados, una inyección de prompt podría afectar la confiabilidad del sistema, comprometer información o generar respuestas inseguras.

Por ello, se busca organizar y comparar mitigaciones evaluadas en estudios recientes, identificando sus alcances, limitaciones y formas de aplicación. Se espera aportar una revisión útil para estudiantes, investigadores y personal de ciberseguridad interesados en comprender los riesgos y controles asociados al uso de LLM en aplicaciones.